

BANK LOAN APPROVAL



CECILIA MORICI

FRANCESCA SELAJ

MORENA FARINELLI

INDICE:

BANK LOAN APPROVAL 1

OBIETTIVO 3

DATASET 3

TRAINING E TEST 8

REGRESSIONE LOGISTICA..... 9

RANDOM FOREST 12

ALBERI DECISIONALI..... 14

CONFRONTO TRA I MODELLI 16

CONCLUSIONI 20

OBIETTIVO

Prevedere la concessione di un prestito personale (variabile target: *Personal.Loan*) sulla base di caratteristiche socioeconomiche dei clienti, utilizzando tecniche di machine learning supervisionato (Logit, Random Forest, Decision Tree) e valutando le prestazioni predittive di ciascun modello.

DATASET

FONTE: Kaggle

Il dataset preso in considerazione riguarda l'approvazione del prestito bancario, esso contiene 5000 righe ognuna delle quali corrisponde ad un soggetto e 14 variabili:

1. **ID:** identificativo univoco per ciascun cliente, essendo i soggetti 5000 la nostra variabile va da 0 a 5000;
2. **Age Customer:** anni del cliente, si tratta di una variabile numerica intera, l'età è compresa tra i 23 anni e i 67 anni;
3. **Customer Experience:** anni di esperienza lavorativa del cliente, variabile numerica che va da 0 a 43;
4. **Consumer Income :** reddito del cliente;
5. **Zip.code :** codice postale della residenza del cliente;
6. **Family:** numero di componenti della famiglia del cliente, range che va da 1 a 4;
7. **Credit Card Avg Score:** spesa/punteggio medio della carta di credito, con un range che va da 0 a 10;
8. **Education :** variabile categorica, indica il livello di istruzione del cliente (UnderGraduate , Graduate, Advanced/Professional);
9. **Mortgage :** valore del mutuo attivo, è una variabile numerica;
10. **Personal.loan :** indica se al cliente è stato accettato un prestito personale (0=NO 1=SI);
11. **Securities Account:** indica se il cliente ha un conto titoli (0=NO 1=SI);
12. **CD Account:** indica se il cliente ha un certificato di deposito (0=NO 1=SI);
13. **Online:** indica se il cliente utilizza servizi bancari online (0=No 1=SI);
14. **Credit Card:** indica se il cliente possiede una carta di credito emessa dalla banca (0=NO 1=SI);

ANALISI DELLE VARIABILI

Si riportano tutte le variabili contenenti le prime sei righe:

	ID	Age	Experience	Income	ZIP.Code	Family	CCAvg	Education	Mortgage	Personal.Loan	Securities.Account	CD.Account	Online	CreditCard
1	2619	23	-3	55	92704	3	2.40	2	145	0	0	0	1	0
2	3627	24	-3	28	90089	4	1.00	3	0	0	0	0	0	0
3	4286	23	-3	149	93555	2	7.20	1	0	0	0	0	1	0
4	4515	24	-3	41	91768	4	1.00	3	0	0	0	0	1	0
5	316	24	-2	51	90630	3	0.30	3	0	0	0	0	1	0
6	452	28	-2	48	94132	2	1.75	3	89	0	0	0	1	0

Nel nostro caso, abbiamo deciso di escludere due variabili: **ID** (identificativo univoco del cliente) e **ZIP Code** (codice postale), poiché non apportano informazioni significative ai fini dell'analisi e potrebbero introdurre distorsioni rispetto all'obiettivo del nostro studio.

Per quanto riguarda la variabile **Experience**, abbiamo rilevato la presenza di valori negativi. Poiché un'esperienza lavorativa negativa non è logicamente coerente, abbiamo scelto di sostituire tali valori con **zero**.

Successivamente, abbiamo esaminato il dataset per verificare la presenza di valori **nulli** e **duplicati**:

```
> sum(is.na(data)) #verifica di valori nulli
[1] 0
> sum(duplicated(data)) #verifica di righe
duplicate
[1] 13
```

Nel nostro caso non sono stati riscontrati valori nulli, mentre sono state identificate solo 13 righe duplicate.

Successivamente, abbiamo analizzato la distribuzione della variabile **Personal.Loan** calcolandone le frequenze assolute tramite il comando `table()`.

```
> table(data$Personal.Loan)
 0    1 4520 
480
```


Dal risultato si evince che:

- 4520 clienti non hanno ricevuto il prestito (0, "NO")
- 480 clienti hanno ricevuto il prestito (1, "YES")

Dal risultato si evince che il dataset presenta uno squilibrio, in quanto la maggior parte dei clienti (90,4%) non ha ricevuto il prestito mentre solo una piccola parte (9,6%) ha ottenuto il prestito.

Intuitivamente, tale sbilanciamento potrebbe influenzare in maniera negativa la performance dei modelli predittivi, specialmente nell'individuare correttamente i casi positivi.

DISTRIBUZIONE DEL PRESTITO




Per ottenere una visualizzazione grafica di tale sbilanciamento, si riportano i grafici relativi alla distribuzione del prestito.

Dal grafico a torta si può notare visivamente come tale variabile sia molto sbilanciata e i valori presenti indicano:

0= Prestito non concesso ("NO")


1= Prestito concesso ("YES")




Per rendere più chiara la comprensione della distribuzione, è stato realizzato un istogramma che mostra visivamente la suddivisione tra i clienti a cui è stato concesso il prestito e quelli a cui non lo è stato.

DISTRIBUZIONE DELLE VARIABILI


I boxplot servono per visualizzare la distribuzione delle variabili numeriche, mostrando massimo, minimo, media, mediana, intervallo interquartile e la presenza di outliers.




La variabile **Age** presenta valori che vanno da un minimo di 23 ad un massimo di 67, con una media di 45.34. Dal boxplot notiamo che non ci sono outlier.




La variabile **Experience** presenta valori che vanno da 0 a 43, con una media di 20.12. Non ci sono outlier.




La variabile **Income** presenta valori che vanno da un minimo di 8 ad un massimo di 224. Dal boxplot si nota che sono presenti molti outlier.




La variabile **Family** presenta valori che vanno da un minimo di 1 ad un massimo di 4, non sono presenti outliers.



La variabile **Mortgage** presenta valori che vanno da un minimo di 0 ad un massimo di 635. Dal boxplot si può notare un'alta presenza di outliers.




La variabile **Education** presenta tre livelli diversi: 1, 2 e 3.




La variabile **CCAvg** presenta valori che vanno da un minimo di 0 ad un massimo di 10000, con una media di 1938. Dal boxplot si può vedere che sono presenti molti outliers.

Nel dataset sono presenti anche delle variabili dicotomiche che possiamo osservare nei seguenti grafici : Personal Loan, Securities Account, CD Account, Online, Credit Card. Possiamo dedurre che Le variabili Personal Loan, Securities Account e CD Account presentano per la maggior parte valori pari a 0, a differenza di Online e Credit Card.



MATRICE DI CORRELAZIONE



L'immagine rappresenta una matrice di correlazione, le correlazioni sono espresse attraverso una scala cromatica continua che varia dal blu (correlazione negativa), al bianco (assenza di correlazione), fino al rosso scuro (correlazione positiva), come indicato nella legenda a destra del grafico. • Correlazioni forti e significative:

- Si osserva una forte correlazione positiva tra Age e Experience (valore vicino a +1), del tutto attesa, in quanto maggiore età implica logicamente maggiore esperienza lavorativa.
- Income mostra una correlazione moderata con CCAvg (spesa media con carta di credito), il che suggerisce che i soggetti con redditi più alti tendono ad avere anche una maggiore media di spesa tramite carta.
- Correlazioni moderate:
- Income è moderatamente correlata in maniera positiva con Mortgage e Personal Loan, indicando che i clienti con redditi più elevati tendono più spesso a sottoscrivere prestiti personali o avere mutui.
- Education mostra una moderata correlazione con Income, coerente con il fatto che livelli di istruzione superiori tendono a corrispondere a redditi maggiori.
- Personal Loan è positivamente correlato con CCAvg, Income e Education, suggerendo che clienti più istruiti e con maggiore capacità di spesa sono più inclini ad accedere a prestiti personali.
- Correlazioni deboli o nulle:

- Molte delle variabili binarie come CD.Account, Securities Account, Online, Credit Card mostrano correlazioni deboli o nulle con la maggior parte delle altre variabili, suggerendo indipendenza statistica o scarsa relazione lineare.
- Family presenta solo deboli correlazioni con le altre variabili, riflettendo una certa eterogeneità tra le dimensioni familiari rispetto alle caratteristiche economiche.

La matrice di correlazione fornisce indicazioni utili per la costruzione di modelli predittivi, poichè le variabili fortemente correlate tra loro potrebbero causare problemi di multicollinearità.

Le relazioni positive tra Income, CCAvg, e Personal Loan suggeriscono una direzione interessante per la segmentazione o la predizione della propensione al prestito.

Nel nostro caso possiamo quindi notare che la maggior parte delle variabili non hanno una forte correlazione, ciò conferma la buona eterogeneità del nostro dataset.

TRAINING E TEST

Il primo step dell'analisi corrisponde alla suddivisione del dataset in **training** e **test** set. Ciò viene fatto per allenare il modello tramite il training set, per imparare i pattern nei dati e costruire la relazione tra le variabili indipendenti e la variabile dipendente. Il modello viene poi valutato sul test set, ovvero si valuta come quest'ultimo si comporta su dati che non ha mai visto prima, per capire se sarà in grado di fare previsioni su dati nuovi. Dividere il dataset in training e test set serve anche per evitare l'overfitting: il modello impara troppo bene dai dati di addestramento (incluse le anomalie) e non riesce a generalizzare bene nei dati del test.

Nel nostro caso la variabile target è *Personal.Loan*, che corrisponde a 0 (NO) quando il cliente non ha ricevuto un prestito personale e 1 (YES) quando il cliente lo ha ricevuto.

Inizialmente il data set è stato diviso in **Training e Test** mantenendo le proporzioni tra le classi: il 75% dei dati vanno nel training e il restante 25% nel test.

```
> split <- sample.split(data$Personal.Loan, SplitRatio = 0.75)
> train_data <- subset (data, split == TRUE)
> test_data <- subset (data, split == FALSE)
```

Viene utilizzata una porzione maggiore di dati per addestrare il modello permettendogli di apprendere i pattern e il restante 25% viene usato per la valutazione delle performance sui dati esclusi durante l'addestramento. Per questo 75-25 è un buon equilibrio tra addestramento efficace e valutazione affidabile delle prestazioni del modello, evitando problemi di *overfitting*, quando un modello è troppo complesso e apprende troppi dettagli dai dati, incluse anomalie.

Successivamente, essendo le classi sbilanciate, abbiamo applicato il metodo del **Cross-validation**, applicando l'upsampling della classe minoritaria (cioè quella dei clienti che hanno ricevuto il prestito), affinché il modello possa apprendere in maniera efficace dalle classi ed evitando la predominanza della classe maggioritaria.


```
> ctrl <- trainControl(
+   method          = "cv", +
+   number          = 5,
+   classProbs      = TRUE,
+   summaryFunction = twoClassSummary,
+   savePredictions = "final",
+   sampling        = "up",
+   verboseIter     = TRUE
+ )
```

È stata utilizzata una *5-fold cross-validation*, dividenti i dati in 5 *fold*: ad ogni iterazione viene usato un *fold* diverso come set di dati di validazione mentre i restanti vengono usati come *training*. Il set di dati di validazione viene usato per calcolare accuratezza e la curva ROC.

Successivamente abbiamo adottato diversi modelli supervisionati valutando l'*accuracy* per determinare quale modello classifica meglio le osservazioni.

REGRESSIONE LOGISTICA

Inizialmente è stato sviluppato un modello predittivo per classificare i clienti in base alla probabilità di ottenere un prestito personale, utilizzando la **regressione logistica**. Quest'ultima è una metodologia usata per prevedere il valore di una variabile dipendente dicotomica sulla base di un insieme di variabili esplicative, qualitative e quantitative. La variabile dipendente è di tipo dicotomico e descrive l'esito riguardante il verificarsi di un evento aleatorio.

Nel nostro caso la variabile target è *Personal.Loan*, che corrisponde a 0 (NO) quando il cliente non ha ricevuto un prestito personale e 1 (YES) quando il cliente lo ha ricevuto.

È stato allenato un modello di regressione logistica binaria (glm), usando tutte le variabili presenti nel data set come predittori.

```
> print(model_logit)
Generalized Linear Model
```

```
3750 samples
 11 predictor
 2 classes: 'NO', 'YES'
```

```
Pre-processing: centered (11), scaled (11)
Resampling: Cross-validated (5 fold)
Summary of sample sizes: 3000, 3000, 3000, 3000, 3000 Additional
sampling using up-sampling prior to pre-processing
```

Resampling results:

ROC	Sens	Spec
0.9600008	0.8923304	0.8888889

I risultati del modello sono:

- ROC(AUC): 0.960: la capacità del modello di discriminare correttamente tra le due classi
- Sensibilità: 0.892: la percentuale di clienti che hanno ottenuto un prestito e che il modello ha correttamente identificato come tali
- Specificità: 0.888: la percentuale di clienti che NON hanno ricevuto un prestito e che il modello ha correttamente identificato

```
> summary(model_logit)
```

```
call:
NULL
```

```
Coefficients:
```

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	0.11945	0.04610	2.591	0.009575	**
Age	-1.42469	0.42278	-3.370	0.000752	***
Experience	1.36732	0.42221	3.238	0.001202	**
Income	2.85956	0.08572	33.359	< 2e-16	***
Family	0.66774	0.04577	14.588	< 2e-16	***
CCAvg	0.53067	0.05925	8.957	< 2e-16	***
Education	1.23659	0.05374	23.011	< 2e-16	***
Mortgage	0.08932	0.04782	1.868	0.061815	.
Securities.Account	-0.42229	0.06465	-6.532	6.50e-11	***
CD.Account	1.48940	0.08336	17.867	< 2e-16	***
Online	-0.28375	0.04622	-6.139	8.33e-10	***
CreditCard	-0.45320	0.05113	-8.864	< 2e-16	*** --

```
-
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
(Dispersion parameter for binomial family taken to be 1)
```

```
Null deviance: 9399.1 on 6779 degrees of freedom
Residual deviance: 3374.8 on 6768 degrees of freedom AIC:
3398.8
```

```
Number of Fisher Scoring iterations: 7
```

Dal modello possiamo vedere che le variabili significative sono Income, Family, CCAvg, Education, Securities.Account, CD.Account, Online e Credit Card, tutte con un p-value minore di 0.05.

Possiamo dedurre quindi che reddito più alto, famiglia più numerosa, Average Score della carta di credito alto, alto livello di educazione e avere un CD account aumentano la probabilità di avere un prestito, essendo i coefficienti stimati positivi.

Mentre possedere un Securities account, avere una banca online e avere una carta di credito diminuiscono la probabilità di avere un prestito, essendo i coefficienti stimati negativi.

Il modello logit è stato poi usato per calcolare le previsioni sul test, ossia la probabilità stimata che un cliente riceva un prestito o no. Essendo i dati sbilanciati (90% NO è 10% YES), è stata impostata una soglia di 0,3, per classificare meglio i casi "YES", ossia i clienti che otterranno un prestito e quindi aumentare la sensibilità del modello.


Confusion Matrix and Statistics

```
Reference
Prediction NO YES
```

NO 952 7
YES 178 113

Dalla *Confusion Matrix* del test set osserviamo che il modello ha classificato correttamente 952 clienti a cui non è stato concesso il prestito e 113 clienti a cui il prestito è stato concesso. I falsi negativi sono soltanto 7, ossia clienti che hanno ottenuto il prestito ma che il modello ha previsto come “NO”. Nonostante ciò, sono presenti 178 falsi positivi, ossia clienti che il modello ha classificato come affidabili, ma che nella realtà non hanno ricevuto il prestito. Il modello ha quindi una buona capacità di individuare correttamente i clienti meritevoli di prestito (bassa percentuale di falsi negativi), ma tende a sovrastimare i casi di approvazione (alta percentuale di falsi positivi).

Il modello ha raggiunto un'accuratezza complessiva dell'85,2%, indicando una buona capacità di distinguere tra clienti interessati e non interessati al prestito personale. Inoltre, la sensibilità è del 94,17%, ciò indica che il modello è molto efficace nell'individuare a cui è stato effettivamente concesso il prestito, infatti ci sono pochi falsi negativi. Infine, la specificità è del 84,25%, per questo la capacità del modello di riconoscere chi non ha ricevuto il prestito in maniera corretta è buona. La specificità è leggermente inferiore alla sensibilità, perché il modello tende di più a classificare alcuni clienti non idonei come idonei, ossia i falsi positivi.



Dalla curva ROC si evince che il modello è efficace nel distinguere tra individui che ricevono il prestito e no. La curva infatti indica un'alta sensibilità e si colloca molto al di sopra della diagonale ($AUC=0.5$), il modello è quindi adatto a minimizzare i falsi negativi, per non perdere clienti validi. L'AUC (Area Under the Curve)

```
> auc(roc_obj)  
Area under the curve: 0.9531
```

L'AUC è di 0.9531, che è un valore molto alto, per questo il modello è in grado di distinguere correttamente tra un cliente a cui è stato concesso il prestito e uno a cui non è stato concesso.

RANDOM FOREST

La **Random Forest**, nota come foresta casuale, è un metodo di apprendimento supervisionato. Questo significa che l'algoritmo impara da un insieme di dati originali già etichettati (cioè sappiamo chi ha ricevuto un prestito e chi no), per poi fare previsioni su nuovi casi. Il modello costruisce inizialmente molti alberi decisionali, ognuno dei quali prende decisioni basandosi su un sottoinsieme casuale dei dati. Ogni albero formula una propria previsione (prediction) su un nuovo caso. Infine, l'algoritmo raccoglie tutte le previsioni dei singoli alberi e decide il risultato finale sulla base della maggioranza delle risposte (dato che si tratta di un problema di classificazione).

La scelta di utilizzare questo modello è motivata dal fatto che la *Random Forest* è particolarmente adatta a gestire dati sbilanciati, come nel nostro caso: 4.520 clienti non hanno ricevuto un prestito, mentre solo 480 lo hanno ottenuto. Questa disparità rende difficile, per altri modelli, prevedere correttamente i casi meno frequenti. La Random Forest, invece, è più robusta rispetto a questo tipo di squilibrio e si rivela adatta per affrontare una classificazione binaria, come quella che ci interessa. Il nostro obiettivo, infatti, è comprendere se un cliente ha ricevuto o meno un prestito, utilizzando la variabile *"Personal.Loan"*, che assume valore 1 (YES) quando il prestito è stato concesso e 0 (NO) quando non lo è stato.

Il modello è stato allenato tramite tecnica di *up-sampling* (replica dei dati monitorati per evitare squilibri con aumento dei casi "YES" per compensare sbilanciamento) e ottimizzato con una griglia di parametri (mtry e min.node.size), selezionando la combinazione migliore tramite validazione incrociata a 5 fold, cioè il dataset è stato diviso in 5 parti per testare la robustezza del modello.

RISULTATI PRINCIPALI DEL MODELLO

Per ogni combinazione si sono ottenute tre metriche: ROC, Sensibilità e Specificità.

```
> print(model_rf)
Random Forest
```

```
3750 samples
 13 predictor
 2 classes: 'NO', 'YES'
```

```
Pre-processing: centered (13), scaled (13)
Resampling: Cross-validated (5 fold)
Summary of sample sizes: 3000, 3000, 3000, 3000, 3000 Additional
sampling using up-sampling prior to pre-processing
```

Resampling results across tuning parameters:

	mtry	min.node.size	ROC	Sens	Spec	
1			0.9953253	0.9941003	0.8944444	2
2	5		0.9957063	0.9938053	0.9055556	
4	1		0.9965851	0.9941003	0.9027778	
4	5		0.9965995	0.9938053	0.9027778	
6	1		0.9965442	0.9935103	0.8972222	
6	5		0.9963291	0.9929204	0.8944444	

Tuning parameter 'splitrule' was held constant at a value of gini ROC was used to select the optimal model using the largest value.

The final values used for the model were `mtry = 4`, `splitrule = gini` and `min.node.size = 5`. Nel risultato si può notare che il modello è stato addestrato su 3750 osservazioni (samples) con 13 variabili predittive, al quale è stato fatto *centering* e *scaling* su tutte le variabili.

Confusion Matrix and Statistics

		Reference Prediction	
NO	YES		
	NO	1127	9
	YES	3	111

Dalla *Confusion Matrix* del test set osserviamo che il modello ha classificato correttamente 1127 clienti a cui non è stato concesso il prestito e 111 clienti a cui il prestito è stato concesso. I falsi negativi sono soltanto 9, ossia clienti che hanno ottenuto il prestito ma che il modello ha previsto come “NO”. Sono presenti solo 3 falsi positivi, ossia clienti che il modello ha classificato come affidabili, ma che nella realtà non hanno ricevuto il prestito. Il modello mostra una capacità predittiva molto bilanciata ed efficace, con un tasso di errore minimo.

In conclusione, il modello Random Forest ha raggiunto un’accuratezza del 98.64% dimostrando ottime capacità predittive, mentre la sensibilità del 91,67% evidenzia un’elevata efficacia nell’identificare correttamente i clienti che ottengono un prestito, infine la specificità del 99,38% conferma l’accuratezza del modello nel riconoscere chi non ne ha fatto richiesta.


ANALISI FINALE MODELLO RANDOM FOREST CON ROC/ACU

Per valutare la capacità di classificazione di un modello abbiamo analizzato la curva ROC, specialmente nel nostro caso con problemi di classificazione binaria sbilanciata.

```
> #Curva ROC e AUC
> roc_rf <- roc(response = test_data$Personal.Loan,
+               predictor = pred_prob_rf,
+               levels = c("NO", "YES"),
+               direction = "<")
```

```
> auc(roc_rf)
Area under the curve: 0.9971
> plot(roc_rf, col = "darkgreen", main = "Curva ROC - Random Forest")
```

Come si evince dal risultato l’AUC (Area Under the Curve) è pari a 0.9971 (valore vicino a 1 indica eccellente separazione tra classi). Nel nostro caso, il valore è quasi perfetto, quindi il modello Random Forest ha un’eccezionale capacità di discriminare i clienti che avranno o meno il prestito.



Dal grafico possiamo concludere che:

- La curva ROC mostra crescita rapida verso in alto a sinistra, che indica un alto tasso di veri positivi e un basso tasso di falsi positivi.
- La retta diagonale rappresenta il caso casuale, $AUC=0.5$, il nostro modello risulta molto al di sopra di essa che indica un'eccellente performance.

ALBERI DECISIONALI

Successivamente sono stati utilizzati gli alberi decisionali, ossia una procedura ricorsiva attraverso la quale un insieme di n unità statistiche vengono progressivamente suddivise in gruppi, secondo una regola di divisione che mira a massimizzare una misura di omogeneità o purezza della variabile di risposta in ciascuno dei gruppi ottenuti.


Inizialmente le variabili categoriali sono state trasformate in fattori per essere interpretate in maniera corretta dal modello, poi i dati sono stati suddivisi in training set (75%) e test set (25%) mantenendo le stesse proporzioni, come precedentemente spiegato.

Successivamente tramite l'istruzione:


```
tree=rpart(Personal.Loan~.,data=train_data,control=rpart.control(cp=0.0001),parms=list(split="gini"))
```

è stato addestrato un albero decisionale usando il criterio di impurità di Gini, che misura la purezza di un nodo in un albero. Il modello cerca di minimizzare l'indice di Gini, per ottenere divisioni che separino le diverse classi in maniera chiara.

Inoltre, il parametro di complessità (CP) impostato è di 0,0001. Si tratta di una soglia imposta al modello: ogni split deve ridurre l'impurità dell'albero per un valore almeno pari al CP per impurità del modello, affinché esso sia considerato utile. Ciò viene fatto per evitare l'overfitting e che l'albero diventi troppo complesso.



Dopo ciò è stato eseguito il pruning dell'albero decisionale tramite il miglior valore di CP (0,008333), che corrisponde al quarto split.



L'immagine raffigura l'albero decisionale che deriva dal modello. Esso inizia dalla radice con il nodo basato sulla variabile Income, con una soglia di 114. I dati si dividono in due gruppi: l'80% avendo un Income minore di 114 va nel ramo sinistro e il restante 20% nel ramo destro.

Nel ramo sinistro il primo split è CCAvg, ossia la spesa media con carta di credito, con una soglia di 3. Se CCAvg è minore di 3 allora si arriva al nodo terminale "NO", con una copertura del 74%, ossia il 74% delle osservazioni soddisfa le condizioni lungo quel ramo. Da ciò deduciamo che la maggior parte delle persone con un reddito basso e con una spesa media con carta di credito bassa rientra nei "NO". Nel caso opposto (CCAvg>3), troviamo un altro split, ossia CD Account. In assenza di esso c'è un ulteriore split con Income con soglia 93, e poi il livello di istruzione con soglia 2. quest'ultimi split portano a tre foglie: la prima predice "NO" con probabilità 0.10 e copertura dell'1%; una che predice "Yes" con probabilità 0.74 e copertura 1%; l'ultima "Yes" con probabilità 0.74 e copertura 1%. La probabilità in un nodo decisionale rappresenta la frazione di esempi che appartengono alla classe positiva "YES" tra tutti i dati che arrivano a quel nodo. Ciò indica che persona con un certo livello di spesa media, senza CD account ma con reddito medio e buona istruzione, sono affidabili (YES). Nel


caso in cui l'individuo abbia un CD Account allora si finisce in un nodo terminale "Yes" con copertura dell'1%.

Nel ramo destro dell'albero ($\text{Income} > 114$) si valuta l'educazione con soglia pari a 2. Se Education è minore di 2, abbiamo un altro split con Family con soglia 3. Se family è minore di 3 allora si arriva ad un nodo "NO" con probabilità 0 e copertura dell'11%, altrimenti si arriva ad un nodo "YES" con probabilità 1 e copertura dell'1%. Se Education è maggiore di 2 allora si arriva ad un nodo "YES" con probabilità 0.94 e copertura del 7%. Ciò significa che individui con redditi alti e livelli di educazione alti saranno affidabili.

Successivamente è stata calcolata la matrice di confusione:

```
> sum(diag(conf.matrix))/sum(conf.matrix)
[1] 0.9869333
> predict_unseen<-predict(tree.pruned, test_data, type="class")
> table_mat<-table(test_data$Personal.Loan, predict_unseen)
> table_mat
predict_unseen
NO  YES
NO  1124    6
YES   10  110
```

Da tale matrice possiamo vedere che il modello classifica correttamente 1124 clienti che non hanno ricevuto il prestito e 110 che lo hanno ricevuto. I falsi negativi sono 6 mentre i falsi positivi sono 10, ciò indica che il modello è in grado di rilevare in maniera corretta i clienti affidabili e non.




L'accuracy calcolata è del 98,69 %, suggerendo alte prestazioni del modello. Infine, calcolando la ROC l'area sotto la curva è del 99,01%, ciò indica che il modello ha un'ottima capacità discriminante tra NO e YES

CONFRONTO TRA I MODELLI

Nella parte finale della nostra analisi è stato effettuato un confronto tra le performance dei modelli predittivi utilizzati. Per valutarne l'efficacia, sono state considerate tre metriche principali: **accuracy**,

sensibilità e specificità. Tale confronto ci consente di comprendere quale algoritmo sia adatto a risolvere il problema, considerando l'equilibrio tra le capacità di individuare correttamente sia i casi positivi che quelli negativi.

Per rendere più chiaro il confronto iniziale tra i modelli predittivi utilizzati (Regressione Logistica, Random Forest e Alberi Decisionali), è stata creata una rappresentazione grafica delle principali metriche di performance. Questo approccio consente di visualizzare in modo immediato le differenze tra i modelli e di valutarne l'efficacia complessiva.



Si nota fin da subito, che:

- L'**Albero Decisionale** mostra valori alti in tutte le metriche, anche se leggermente inferiori rispetto alla Random Forest, suggerendo comunque buone prestazioni, ma complessivamente inferiori rispetto a quest'ultimo.
- Il modello di **Regressione Logistica** mantiene una buona specificità, ma presenta una sensibilità leggermente inferiore. Questo suggerisce che potrebbe avere maggiori difficoltà nel riconoscere i casi positivi rispetto agli altri modelli.
- il modello **Random Forest** risulta il più performante nel complesso. Questo modello mostra valori elevati in tutte le metriche, mantenendo un buon equilibrio tra la capacità di riconoscere correttamente sia i casi positivi, grazie all'alta sensibilità, sia i casi negativi, grazie all'elevata specificità.

Per facilitare una comprensione più approfondita di questa rappresentazione, viene riportata una sintesi dei valori numerici, che ci permettono di esaminare con maggiore dettaglio il confronto. Per effettuare tale confronto numerico, si utilizza la *Confusion Matrix*, una tabella che mette a confronto le previsioni di un modello con i valori reali, facilitando così la comprensione degli errori commessi dal modello. Nella tabella sono riportati quattro valori principali: True Positives (TP), True Negatives (TN), False Positives (FP) e False Negatives (FN). Da questi valori è possibile derivare le metriche necessarie per valutare la performance del modello.

REGRESSIONE LOGISTICA

```
> confusionMatrix(pred_class, test_data$Personal.Loan, positive = "YES") #accuracy 82%
Confusion Matrix and Statistics
```

	Reference	
Prediction	NO	YES
NO	952	7
YES	178	113

```
Accuracy : 0.852
          95% CI : (0.8311, 0.8712)
No Information Rate : 0.904
P-Value [Acc > NIR] : 1
          Kappa : 0.4791
```

```
McNemar's Test P-Value : <2e-16
          Sensitivity : 0.9417
          Specificity : 0.8425
          Pos Pred Value : 0.3883
          Neg Pred Value : 0.9927
          Prevalence : 0.0960
          Detection Rate : 0.0904
          Detection Prevalence : 0.2328
          Balanced Accuracy : 0.8921
```

```
'Positive' Class : YES
```

Dai risultati emerge che il modello ha:

- **Accuratezza** del 85,2%, ovvero ha predetto correttamente l'etichetta nel 85,2% dei casi, indicando una performance positiva
- **Sensibilità** (recall o True Positive Rate) del 94,17%, cioè ha identificato correttamente il 94,17% dei casi positivi, ovvero coloro che hanno effettivamente preso il prestito ("YES").
- **Specificità** (True Negative Rate) dell'84,25%, indicando che ha rilevato correttamente l'84,25% dei casi negativi, ovvero coloro che non hanno preso il prestito ("NO").
- **Precisione** (Pos Pred Value) del 38,83%, che suggerisce un valore relativamente basso, poiché molte delle previsioni positive sono errate.

Tuttavia, il modello nel complesso mostra una buona accuratezza e risulta molto sensibile nel rilevare i casi positivi, mentre presenta una bassa precisione per i casi positivi, suggerendo che potrebbe commettere molti falsi positivi. Tuttavia, la specificità indica che è efficace nel rilevare i casi negativi.

RANDOM FOREST

```
> confusionMatrix(pred_class_rf, test_data$Personal.Loan, positive = "YES") #accuracy 98%
Confusion Matrix and Statistics
```

	Reference Prediction	
NO	YES	
	NO	1124
	YES	9

YES 6 111

Accuracy : 0.988

95% CI : (0.9803, 0.9933)

No Information Rate : 0.904

P-Value [Acc > NIR] : <2e-16

Kappa : 0.9301

McNemar's Test P-Value : 0.6056

Sensitivity : 0.9250

Specificity : 0.9947

Pos Pred Value : 0.9487

Neg Pred Value : 0.9921

Prevalence : 0.0960

Detection Rate : 0.0888

Detection Prevalence : 0.0936

Balanced Accuracy : 0.9598

'Positive' Class : YES

Dai risultati emerge che il modello Random Forest ha:

- **Accuratezza** totale pari a 98,8%, indicando una performance molto positiva.
- **Sensibilità** (recall o True Positive Rate) del 92,50%, ovvero ha identificato correttamente il 92,50% dei casi positivi, coloro che hanno effettivamente preso il prestito ("YES").
- **Specificità** (True Negative Rate) del 99,47%, mostrando che ha rilevato correttamente il 99,47% dei casi negativi, coloro che non hanno preso il prestito ("NO").
- **Precisione** (Pos Pred Value) del 94,87%, indicando che la maggior parte delle previsioni positive sono corrette.

Nel complesso, il modello mostra un'eccellente accuratezza e si dimostra altamente sensibile nell'identificare i casi positivi, con un'elevata precisione che contribuisce a ridurre i falsi positivi.

L'alta specificità evidenzia inoltre una grande efficacia nel riconoscere i casi negativi. **ALBERI**

DECISIONALI

```
> conf.matrix<-table(train_data$Personal.Loan, predict(tree.pruned, type="vector"))
> conf.matrix
      1      2
NO 3369    21
YES   28   332
> rownames(conf.matrix)<-paste("Actual", rownames(conf.matrix), sep=":")
> colnames(conf.matrix)<-paste("Pred", colnames(conf.matrix), sep=":")
> sum(diag(conf.matrix))/sum(conf.matrix) ##accuratezza di circa 98%
[1] 0.9869333
> predict_unseen<-predict(tree.pruned, test_data, type="class")
> table_mat<-table(test_data$Personal.Loan, predict_unseen)
> table_mat
predict_unseen
NO YES
NO 1124    6
YES  10  110
> sum(diag(table_mat))/sum(table_mat) ##circa 98% accuracy
[1] 0.9872
> ## PRECISIONE
> TP <- table_mat[2, 2] # True Positives (107)
> FP <- table_mat[1, 2] # False Positives (4)
```

```

> TN <- table_mat[1, 1] # True Negative
> FN <- table_mat[2, 1] # False Negative
> precision <- TP / (TP + FP) >
cat("Precisione:", precision, "\n")
Precisione: 0.9482759
> ## SENSIBILITA (RECALL)
> sensibilità <- TP / (TP + FN)
> cat("Sensibilità:", sensibilità, "\n")
Sensibilità: 0.9166667
> ## SPECIFICITA (TRUE NEGATIVE RATE)
> specificità <- TN / (TN + FP)
> cat("Specificità:", specificità, "\n") Specificità:
0.9946903

```

Dai risultati emerge che il modello **Decision Tree** ha:

- **Accuratezza** complessiva del **98,7%**, cioè, ha predetto in modo corretto l'etichetta nel 98,7% dei casi, dimostrando una performance positiva.
- **Sensibilità** (recall o True Positive Rate) del **91,67%**, ha identificato correttamente il 91,67% dei casi positivi, di coloro che hanno preso il prestito ("YES").
- **Specificità** (True Negative Rate) del **99,47%**, dimostrando che ha rilevato correttamente il 99,47% dei casi negativi, di coloro che non hanno preso il prestito ("NO").
- **Precisione** (Pos Pred Value) del **94,83%**, indica un buon valore, cioè che la maggior parte delle previsioni positive sono corrette.

In sintesi, il modello mostra un'ottima accuratezza e un'elevata sensibilità nell'individuare i casi positivi, accompagnata da una precisione altrettanto alta, che contribuisce a contenere il numero di falsi positivi. La specificità risulta anch'essa molto elevata, segnalando una notevole capacità di identificare correttamente i casi negativi. Nel complesso, le elevate prestazioni suggeriscono un modello ben equilibrato e già ottimizzato, con spazi di miglioramento molto ridotti.

In base ai risultati ottenuti, il modello Random Forest si distingue chiaramente come la soluzione più efficiente e affidabile tra tutti quelli presi in esame, tale modello si configura come quello più robusto, preciso e bilanciato, ideale per affrontare il problema predittivo oggetto dell'analisi, garantendo performance rispetto ad altri modelli presi sotto esame.

CONCLUSIONI

L'analisi condotta ha evidenziato come, partendo da un dataset sbilanciato nella variabile target **Personal.Loan**, sia possibile sviluppare modelli predittivi efficaci per stimare la probabilità che un cliente ottenga un prestito personale. La fase esplorativa ha permesso di identificare la presenza di alcune criticità (come sbilanciamenti e valori negativi non coerenti), nonché di individuare variabili fortemente correlate con l'esito del prestito, come *Income*, *Education* e *CCAvg*.

Tra i modelli supervisionati implementati — regressione logistica, Random Forest e albero decisionale — il modello Random Forest si è rivelato il più performante. In particolare, ha mostrato:

- Accuratezza del 98,8%, sensibilmente superiore agli altri modelli;
- Sensibilità del 92,5%, che garantisce una corretta individuazione della maggior parte dei clienti che ottengono un prestito;

- Specificità del 99,47%, indicando una fortissima capacità nel riconoscere i casi negativi;
- AUC pari a 0,9971, segno di eccellente capacità discriminante;

Al contrario, la regressione logistica, pur essendo interpretabile e utile per comprendere l'effetto delle singole variabili, ha evidenziato una minore precisione nei casi positivi, a causa dell'elevato numero di falsi positivi. L'albero decisionale, infine, ha ottenuto buoni risultati in termini di accuratezza e interpretabilità, ma si sono dimostrati leggermente inferiori alla Random Forest in tutte le metriche chiave.

Pertanto, si può concludere che la Random Forest rappresenta il modello più robusto e affidabile per la previsione della concessione di prestiti personali, soprattutto in contesti con classi sbilanciate e numerose variabili eterogenee. Questo approccio consente di ottimizzare il processo decisionale bancario, riducendo al minimo i rischi di concessione errata e massimizzando l'efficienza operativa.

Il random forest, infatti, è un modello ensemble che combina più alberi decisionali decorrelati e prende la decisione finale tramite maggioranza. Combinare più modelli di apprendimento aumenta la performance finale del modello e diminuisce quindi la varianza.

